


# Inteligência Artificial

Machine Learning – Conceitos Introdutórios

Profº - Dr. Thales Levi Azevedo Valente

[thales.l.a.valente@gmail.com.br](mailto:thales.l.a.valente@gmail.com.br)

# Grupo da turma 2024.2



<https://chat.whatsapp.com/JFB6CgOI7IMCoYmolKEK62>

# Sejam Bem-vindos !



**Os celulares devem  
ficar no silencioso  
ou desligados**

Pode ser utilizado  
apenas em caso  
de emergência



**Boa tarde/noite, por  
favor e com licença  
DEVEM ser usados**

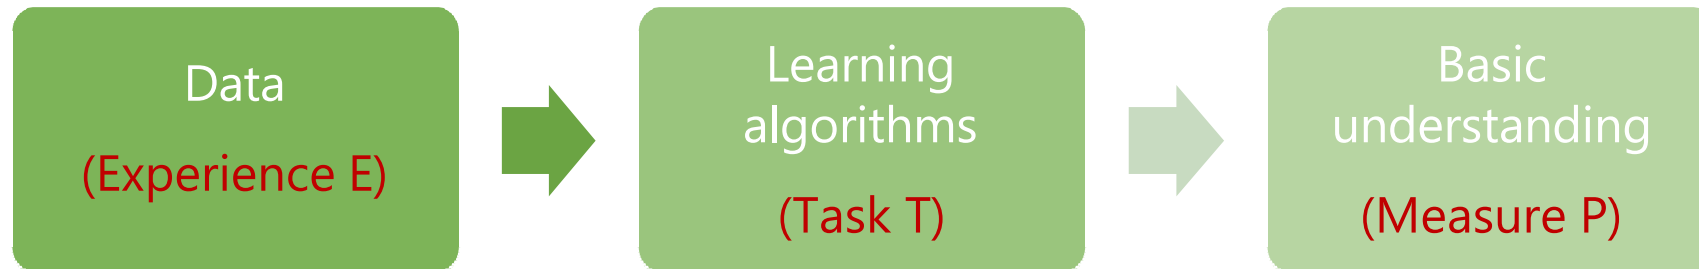
Educação é  
essencial

# Machine Learning

## Introdução

---

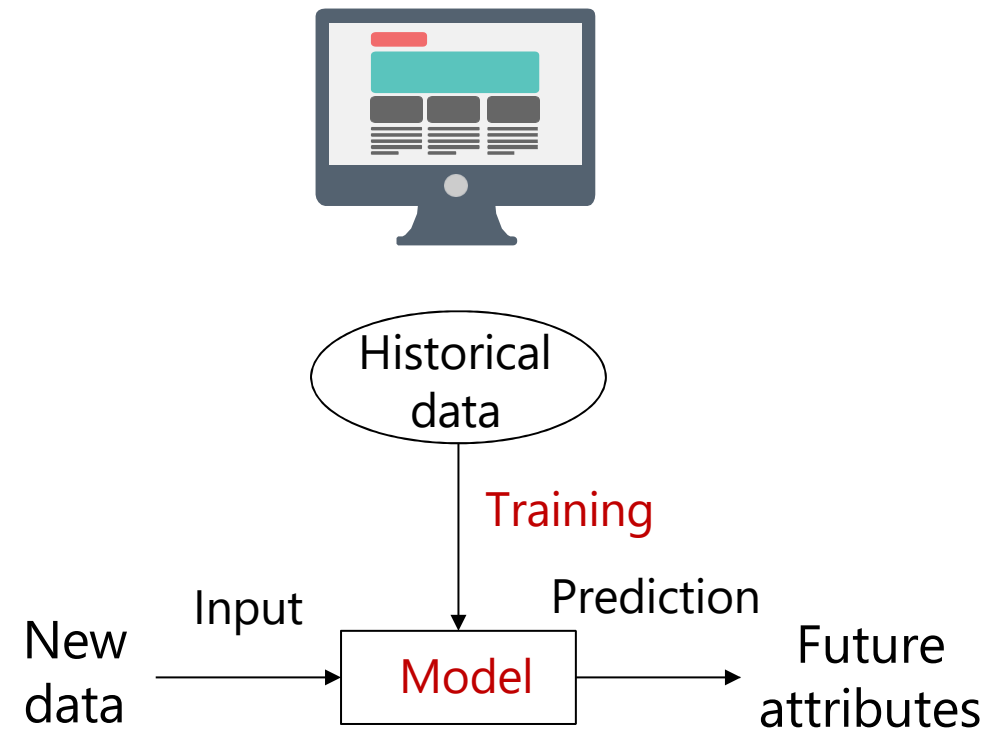

- A aprendizagem de máquina é o estudo dos algoritmos de aprendizado.
- Diz-se que um programa de computador aprende com a experiência (E) em relação a uma classe de tarefas (T) e medida de desempenho (D) se seu desempenho nas tarefas, conforme medido por D , melhora com a experiência.



# Machine Learning


## Introdução

---

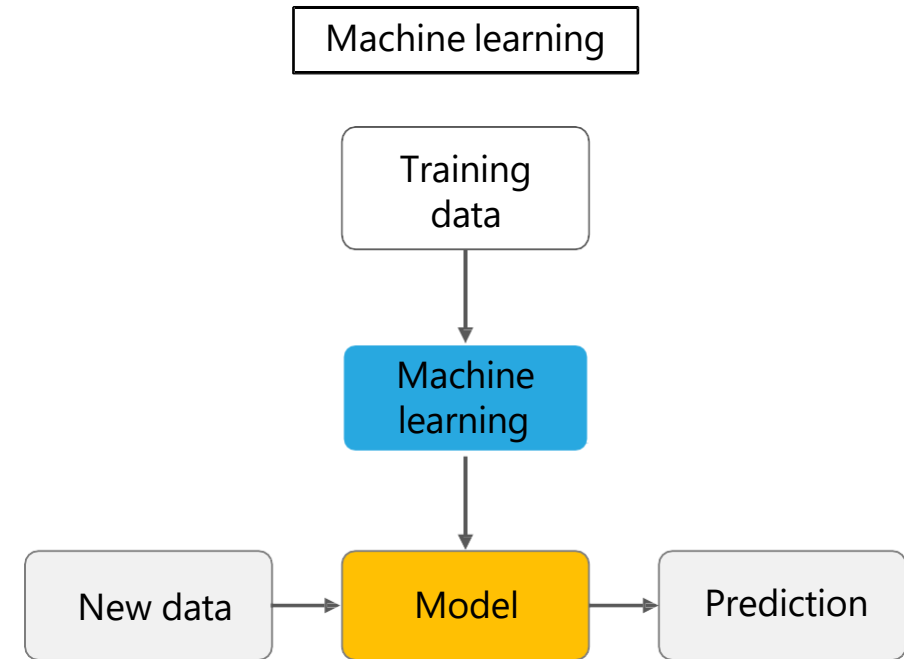


# Machine Learning

## Machine Learning vs Sistemas baseados em regras



- Explicit programming is used to solve problems.
- Rules can be manually specified.




- Samples are used for training.
- The decision-making rules are complex or difficult to describe.
- Rules are automatically learned by machines.

# Machine Learning

## Cenários

- A solução para um problema é complexa, ou o problema pode envolver uma grande quantidade de dados sem uma função de distribuição de dados clara.

*Rules are complex or cannot be described, such as facial recognition and voice recognition.*



*Task rules change over time. For example, in the part-of-speech tagging task, new words or meanings are generated at any time.*



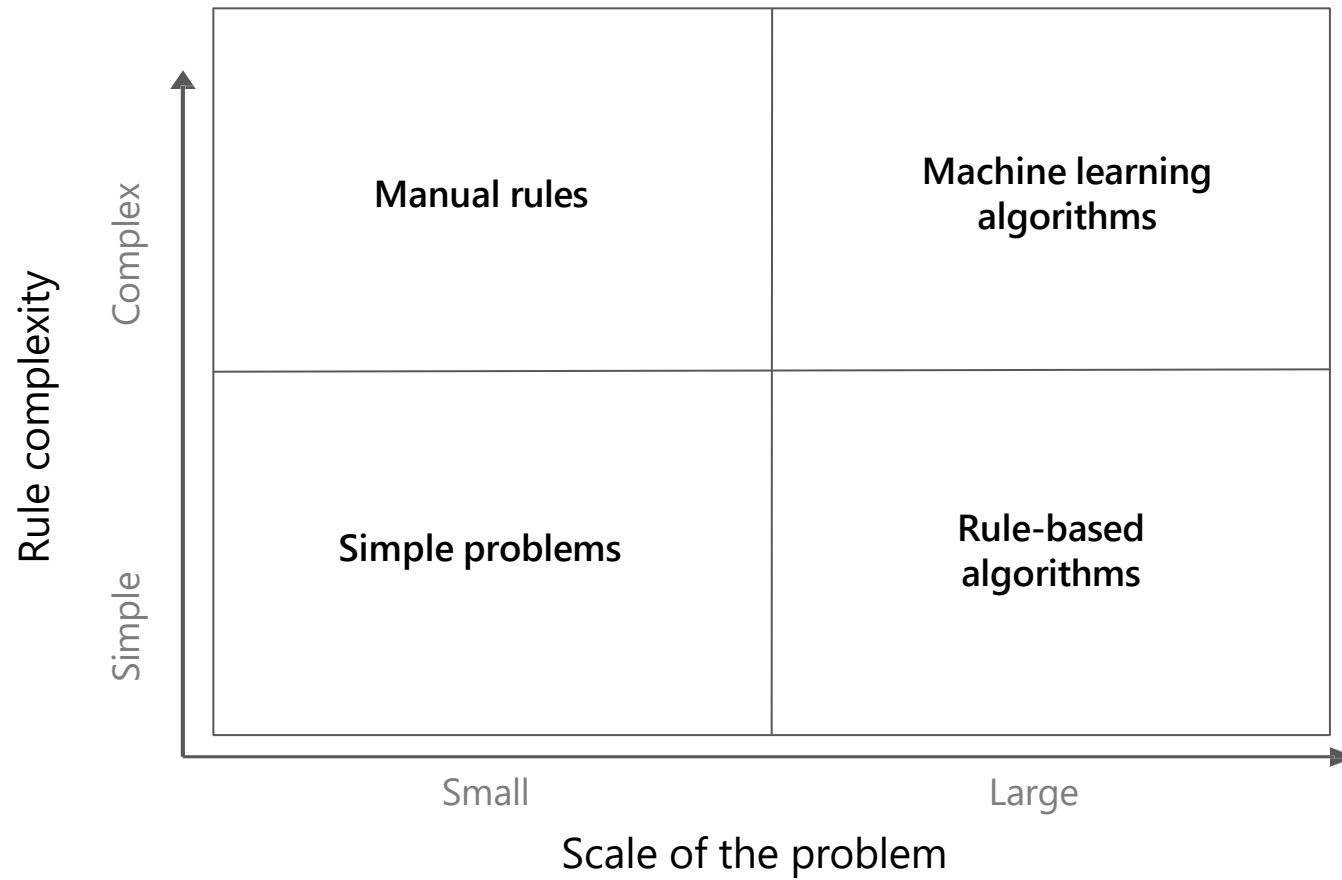
*Data distribution changes over time, requiring constant readaptation of programs, such as predicting the trend of commodity sales.*



# Machine Learning

## Cenários

- **A solução para um problema é complexa, ou o problema pode envolver uma grande quantidade de dados sem uma função de distribuição de dados clara.**

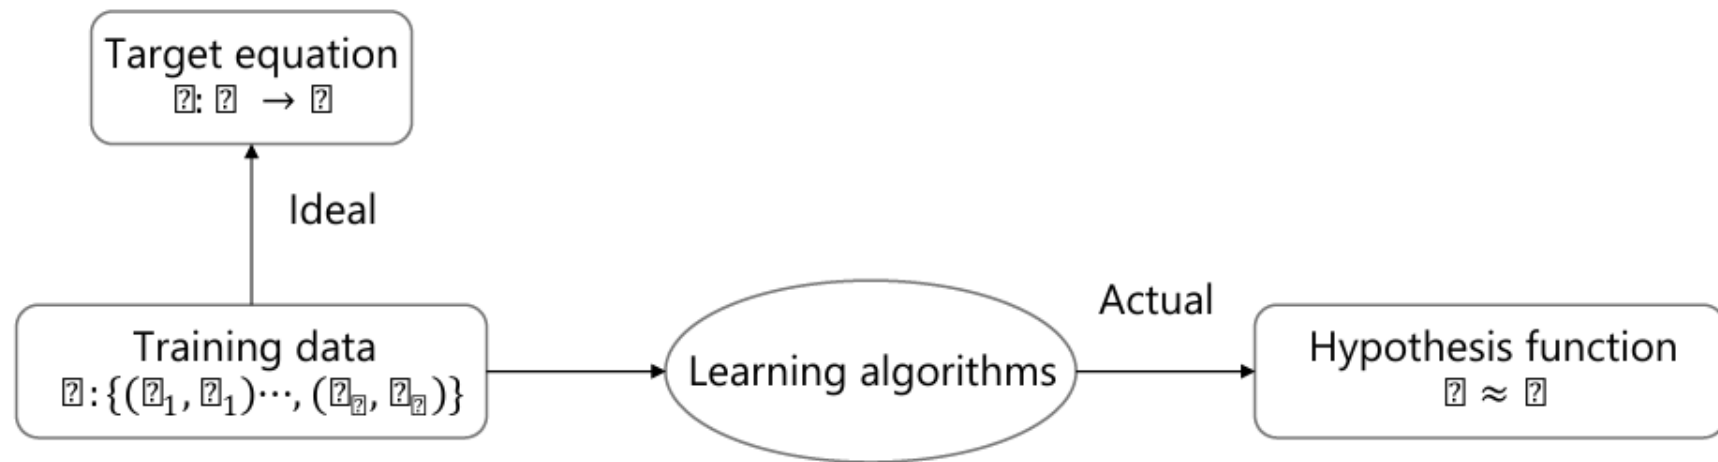




# Machine Learning

## Idéia

- A função alvo  $f$  é desconhecida. Os algoritmos de aprendizado não conseguem obter uma função  $f$  perfeita.
- Assuma que a função hipótese  $g$  aproxima a função  $f$ , mas pode ser diferente da função  $f$ .




# Machine Learning

## Principais tipos de problemas

### ■ Classificação

- ✓ Um programa de computador precisa especificar a qual das  $k$  categorias um determinado input pertence.
- ✓ Para realizar essa tarefa, os algoritmos de aprendizado geralmente geram uma função  $f: X \rightarrow \{1, 2, \dots, k\}$ . Por exemplo, o algoritmo de classificação de imagens em visão computacional é desenvolvido para lidar com tarefas de classificação.




# Machine Learning

## Principais tipos de problemas

---

### ■ Regressão

- ✓ um programa de computador prevê a saída para um dado input. Os algoritmos de aprendizado normalmente geram uma função  $f:X \rightarrow Y$ , onde  $Y$  é um valor contínuo.
- ✓ Um exemplo desse tipo de tarefa é prever o valor de uma ação.

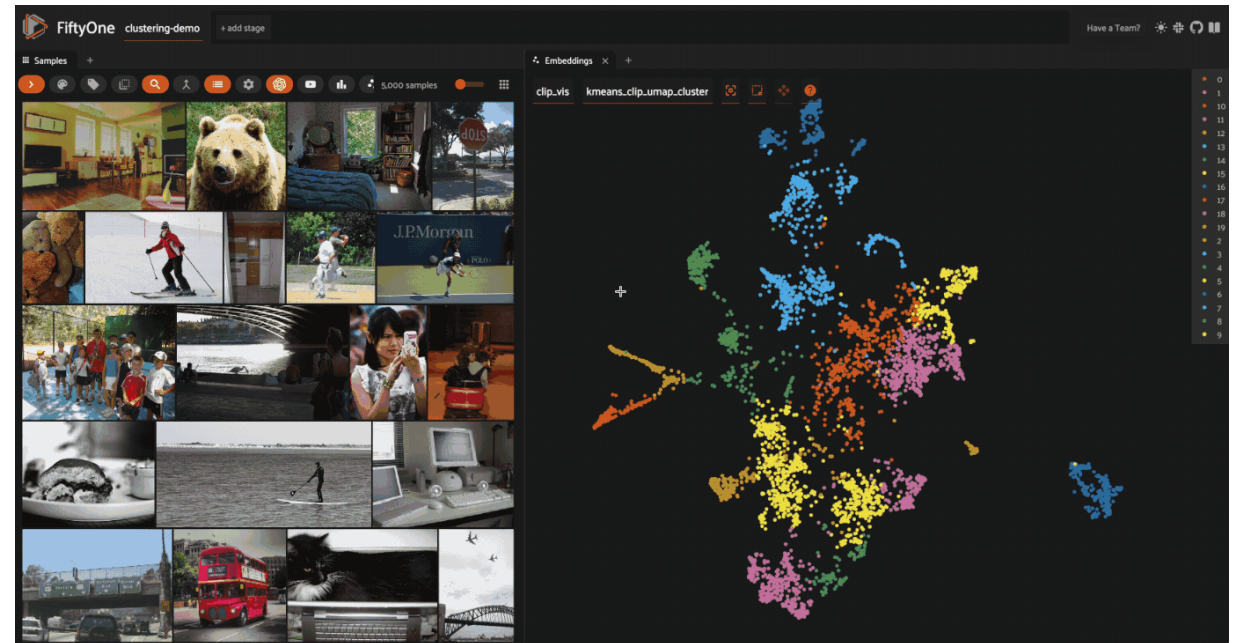



# Machine Learning

## Principais tipos de problemas

### ■ Clusterização

- ✓ Uma grande quantidade de dados de um conjunto de dados não rotulados é dividida em várias categorias com base na semelhança interna dos dados.
- ✓ Dados na mesma categoria são mais semelhantes entre si do que os dados em categorias diferentes.

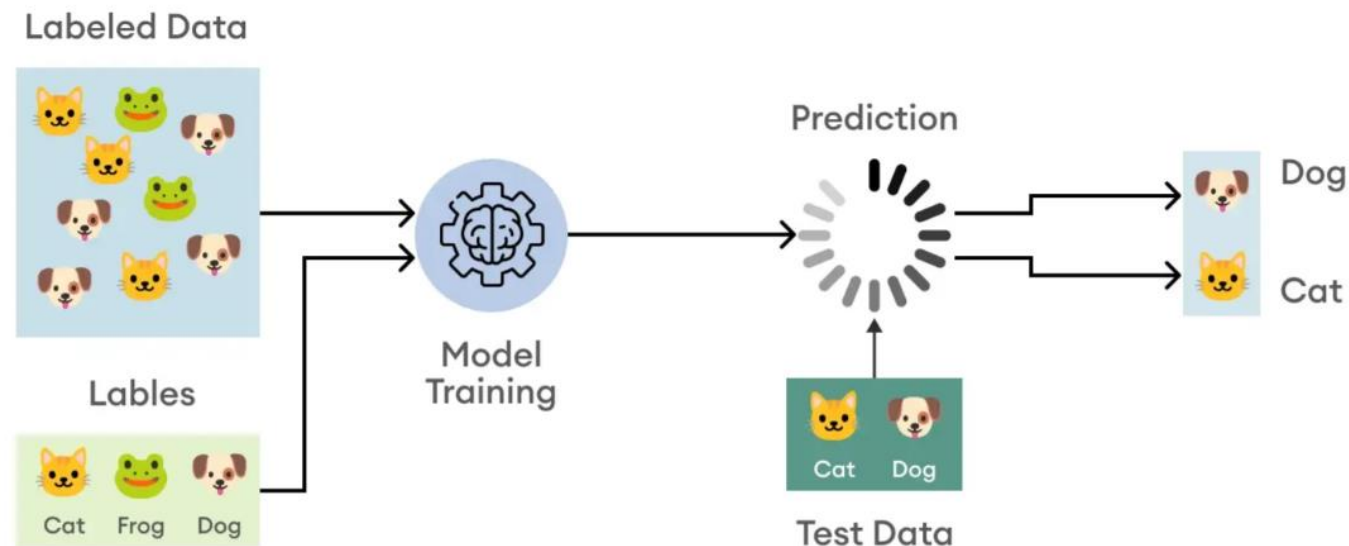


# Machine Learning

## Tipos de Aprendizado

### ■ Supervisionado

- ✓ Obter um modelo ótimo com o desempenho necessário através do treinamento e aprendizado com base nas amostras de categorias conhecidas.
- ✓ Em seguida, usa-se o modelo para mapear todas as entradas para as saídas e verificar a saída com o objetivo de classificar dados desconhecidos.




# Machine Learning

## Tipos de Aprendizado

### ■ Não-Supervisionado

- ✓ Para amostras não rotuladas, os algoritmos de aprendizado modelam diretamente os conjuntos de dados de entrada. O agrupamento (clustering) é uma forma comum de aprendizado não supervisionado.
- ✓ Nesse caso, precisamos apenas agrupar amostras altamente semelhantes, calcular a similaridade entre novas amostras e as existentes, e classificá-las com base nessa similaridade.




# Machine Learning

## Tipos de Aprendizado

### ■ Aprendizado por reforço

- ✓ Se preocupa com a forma como os agentes devem tomar ações em um ambiente para maximizar uma noção de recompensa acumulada.
- ✓ A diferença entre o aprendizado por reforço e o aprendizado supervisionado está no sinal do professor. O sinal de reforço fornecido pelo ambiente no aprendizado por reforço é usado para avaliar a ação em vez de dizer ao sistema de aprendizado como realizar as ações corretas.



# Machine Learning

## Tipos de Aprendizado

---

### ■ **Aprendizado por reforço – curiosidade – Experimento de Pavlov**

- ✓ O experimento de Pavlov é um dos mais famosos estudos de condicionamento clássico na psicologia.
- ✓ Ivan Pavlov, fez uma descoberta acidental que acabou sendo fundamental para o desenvolvimento da teoria do condicionamento clássico.
  - ✓ Pavlov estava realizando uma pesquisa sobre o sistema digestivo
  - ✓ Observou que, ao apresentar comida aos cães, eles começavam a salivar antes mesmo de ingerir o alimento
  - ✓ Esse reflexo antecipado da salivação não era esperado e despertou seu interesse

### - Investigação

- ✓ Por que os cães salivavam em resposta a estímulos que estavam associados à comida, como a visão do alimento ou o som de um sino?



# Machine Learning

## Tipos de Aprendizado

---


### ▪ **Aprendizado por reforço – curiosidade – Experimento de Pavlov**

- ✓ Pavlov começou a realizar experimentos controlados com uso de um sino como estímulo neutro (um estímulo que, inicialmente, não causava resposta nos cães)
- ✓ Fase de aquisição (condicionamento)
  - ✓ Pavlov tocava o sino antes de apresentar a comida aos cães.
  - ✓ Depois de várias repetições, os cães começaram a associar o som do sino com a chegada do alimento
- ✓ Fase de teste
  - ✓ Após várias associações, Pavlov tocava o sino sem apresentar comida, e os cães começavam a salivar, mesmo sem a presença do alimento.
  - ✓ Isso demonstrou que eles haviam aprendido a associar o som do sino à comida.
- ✓ Seu trabalho foi publicado em 1904, quando ele recebeu o Prêmio Nobel de Fisiologia ou Medicina

# Machine Learning

## Tipos de Aprendizado

### ■ Aprendizado por reforço – curiosidade – Experimento de Pavlov



# Machine Learning

## Tipos de Aprendizado

---

### ■ **Aprendizado por reforço – curiosidade – Experimento de Pavlov**

- ✓ No aprendizado por reforço, um agente aprende a tomar decisões em um ambiente para maximizar a recompensa acumulada ao longo do tempo
  - ✓ **A idéia de associar ações a recompensas é fundamental**
  - ✓ **Pavlov, portanto, contribuiu para o entendimento de como os sistemas podem aprender e se adaptar com base no feedback do ambiente**
- ✓ Assim como Pavlov mostrou que um estímulo condicionado (o sino) pode provocar uma resposta automática (salivação), no aprendizado por reforço, as ações do agente podem se tornar condicionadas a certos estados do ambiente, dependendo das recompensas que o agente recebe ao longo do tempo.
- ✓ Mais tarde seria formalizado em modelos de aprendizado por reforço, como os de Q-learning ou os algoritmos de política, que associam ações a recompensas específicas para maximizar a performance do agente ao longo do tempo

# Machine Learning

## Tipos de Aprendizado

### ■ **Aprendizado por reforço – curiosidade – Experimento de Skinner**

- ✓ Enquanto Pavlov focou no condicionamento clássico, que se baseia em associar um estímulo a uma resposta, Skinner se concentrou no condicionamento operante
  - ✓ Se refere ao processo pelo qual as consequências de uma ação influenciam a probabilidade dessa ação ser repetida
  - ✓ A ação do organismo é vista de maneira ativa sobre o ambiente e é recompensado ou punido com base nas suas ações
- ✓ Skinner acreditava que o comportamento humano e animal é controlado por suas consequências e que comportamentos podem ser reforçados ou desencorajados com base nos resultados que seguem as ações.
  - ✓ Reforços e punições são usados para aumentar ou diminuir a probabilidade de um comportamento ocorrer novamente

# Machine Learning

## Tipos de Aprendizado

### ■ **Aprendizado por reforço – curiosidade – Experimento de Skinner**

- ✓ A caixa de Skinner consistia em uma câmara fechada onde um animal podia realizar uma ação (por exemplo, pressionar uma alavanca) para obter uma recompensa (geralmente comida)
- ✓ A caixa permitia que ele manipulasse variáveis como o tipo de reforço (positivo ou negativo), o intervalo de tempo entre a ação e a recompensa, e a frequência de reforços. **Skinner identificou três tipos de consequências para o comportamento**
- ✓ **Skinner acreditava que o comportamento humano e animal é controlado por suas consequências e que comportamentos podem ser reforçados ou desencorajados com base nos resultados que seguem as ações.**
  - ✓ **Reforços e punições são usados para aumentar ou diminuir a probabilidade de um comportamento ocorrer novamente**

# Machine Learning

## Tipos de Aprendizado

### ■ **Aprendizado por reforço – curiosidade – Experimento de Skinner**

- ✓ A caixa permitia que ele manipulasse variáveis como o tipo de reforço (positivo ou negativo), o intervalo de tempo entre a ação e a recompensa, e a frequência de reforços. Skinner identificou três tipos de consequências para o comportamento




# Machine Learning

## Tipos de Aprendizado

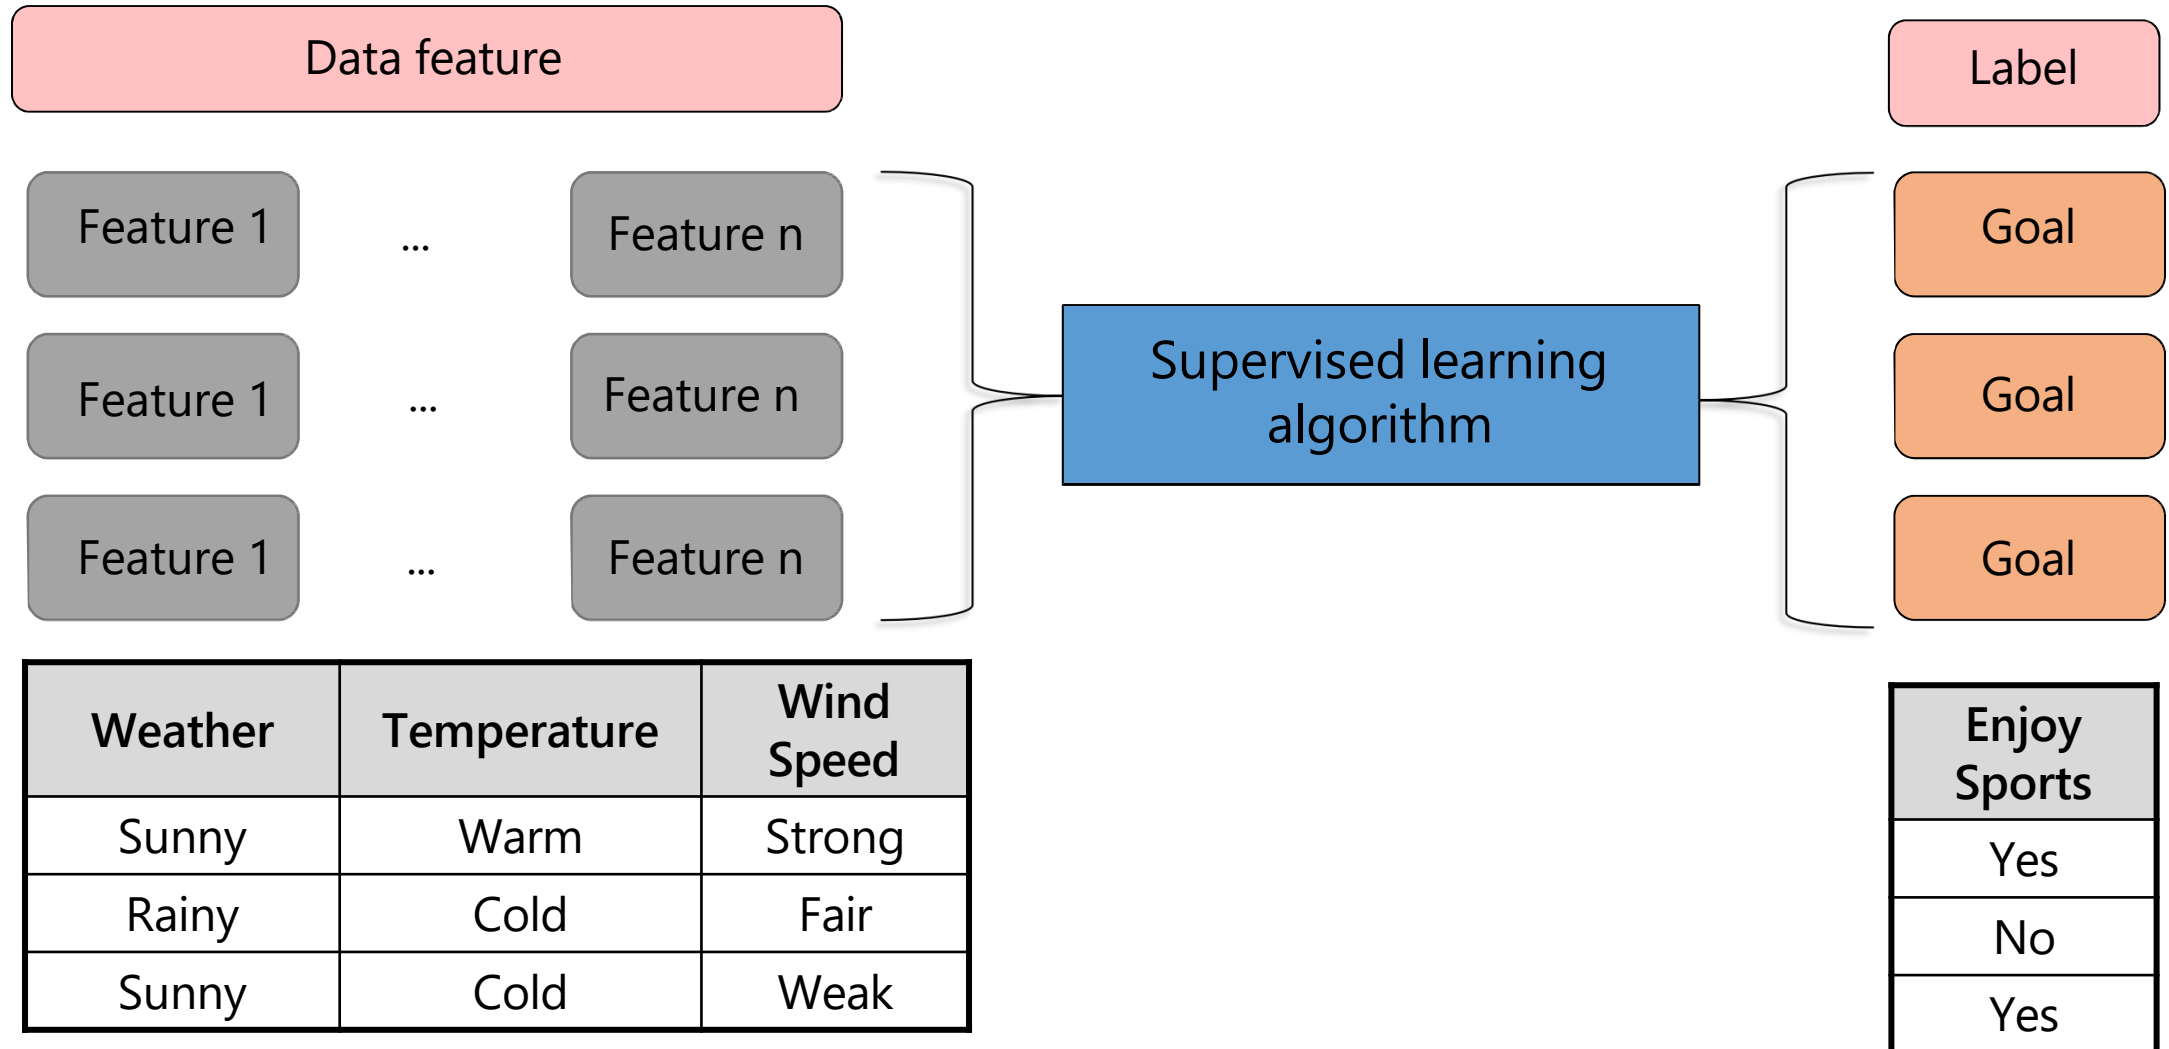
### ▪ **Aprendizado por reforço – curiosidade – Experimento de Skinner**

- ✓ **Reflexos positivos:** Quando um comportamento é seguido por uma recompensa (reforço positivo), a probabilidade de o comportamento ser repetido aumenta.
- ✓ **Punições:** Quando um comportamento é seguido por uma consequência desagradável, a probabilidade de esse comportamento ocorrer novamente diminui.
- ✓ **Reflexos negativos:** Quando um comportamento é seguido pela remoção de um estímulo aversivo (reforço negativo), também aumenta a probabilidade de o comportamento ser repetido.



# Machine Learning

## Aprendizado Supervisionado






# Machine Learning

## Classificação

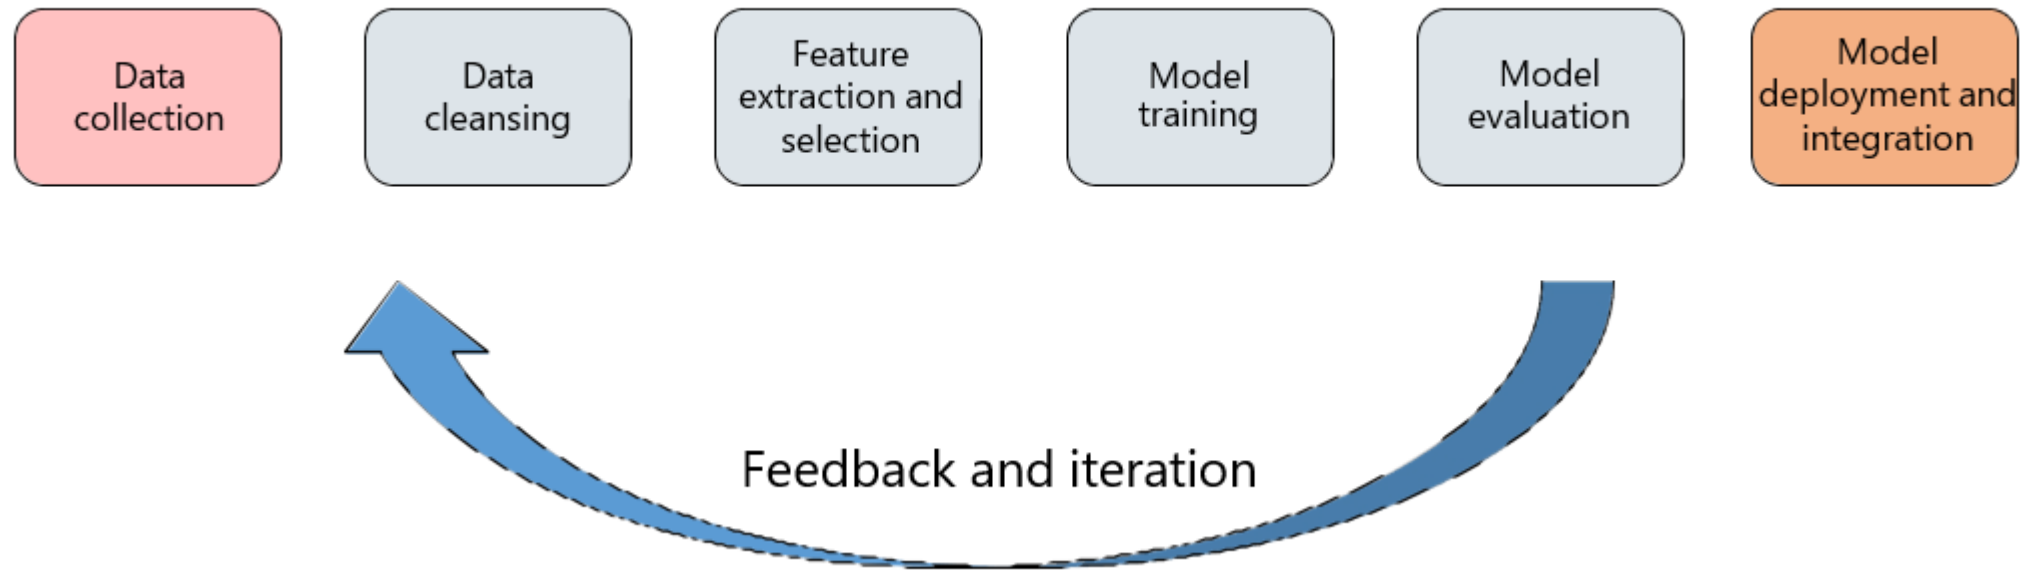
- **Mapeia amostras em um conjunto de dados amostral para uma categoria específica usando um modelo de classificação.**
- **Responde a perguntas como:**
  - ✓ Haverá um engarrafamento na estrada XX durante o horário de pico da manhã amanhã?
  - ✓ Qual método é mais atraente para os clientes: um voucher de 5 yuan ou 25% de desconto?



# Machine Learning

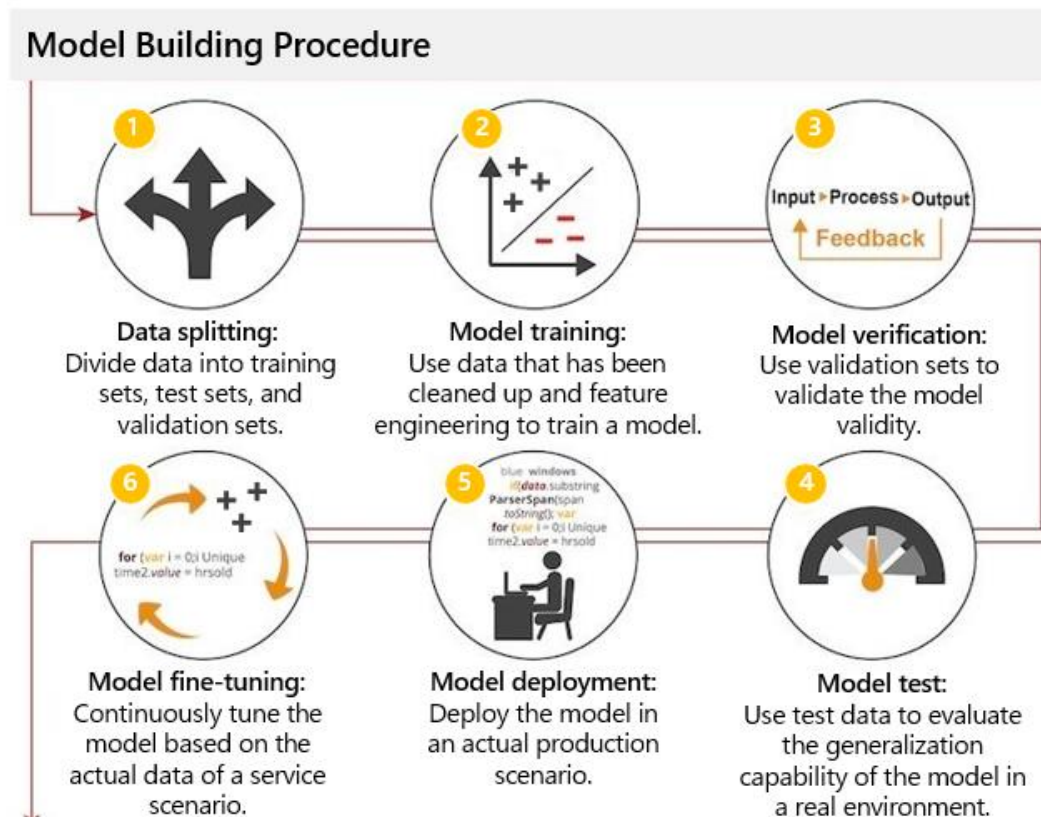
## Conceitos básicos - pipeline geral

---



# Machine Learning

## Conceitos básicos – pipeline de construção do modelo




# Machine Learning

## Conceitos básicos - dataset

### ■ Conjunto de dados (Dataset)

- ✓ Uma coleção de dados usada em tarefas de aprendizado de máquina.
- ✓ Cada registro de dados é chamado de amostra.
- ✓ Os eventos ou atributos que refletem o desempenho ou a natureza de uma amostra em um determinado aspecto são chamados de características (features).
- ✓ Labels refletem a resposta esperada para cada amostra.

		Feature 1	Feature 2	Feature 3	Label	
		No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000	
	2	120	9	Southwest	1300	
	3	60	6	North	700	
	4	80	9	Southeast	1100	
Test set	5	95	3	South	850	



# Machine Learning

## Conceitos básicos – divisão de dados

---

### ■ **Hold-out**

- ✓ É o método mais simples de validação. Consiste em separar os dados em duas (ou três) partes: Treino, Teste e possível terceira subdivisão (Validação) [opcional]
- ✓ Como é feito? Escolhe-se uma proporção de partição (ex: 80-20 ou 60-20-20)
- ✓ Vantagens
  - ✓ Simplicidade: fácil de implementar; basta dividir os dados uma única vez.
  - ✓ Rapidez: ideal quando o conjunto de dados é grande e o treinamento precisa ser mais ágil.
- ✓ Desvantagens
  - ✓ Dependência da partição: se os dados forem divididos de forma desfavorável (por exemplo, desbalanceados em alguma parte), a avaliação pode não refletir bem o desempenho real.
  - ✓ Menor aproveitamento dos dados para treino: se você separa 30% ou mais para teste, está “perdendo” dados que poderiam ajudar no treinamento.

# Machine Learning

## Divisão de dados – hold-out


		Feature 1	Feature 2	Feature 3	Label	
		No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000	
	2	120	9	Southwest	1300	
	3	60	6	North	700	
	4	80	9	Southeast	1100	
Test set	5	95	3	South	850	

# Machine Learning


## Divisão de dados – hold-out

### ▪ Conjunto de treinamento (Training set)

- ✓ Um conjunto de dados usado no processo de treinamento, onde cada amostra é chamada de amostra de treinamento.
- ✓ O processo de criação de um modelo a partir dos dados é chamado de aprendizado (treinamento).
- ✓ Geralmente é subdividido em 2 grupos: treino e validação, onde o primeiro é usado para ajustar o modelo e o segundo para simular **desempenho em dados novos**.



		Feature 1	Feature 2	Feature 3	Label	
		No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000	
	2	120	9	Southwest	1300	
	3	60	6	North	700	
	4	80	9	Southeast	1100	
Test set	5	95	3	South	850	



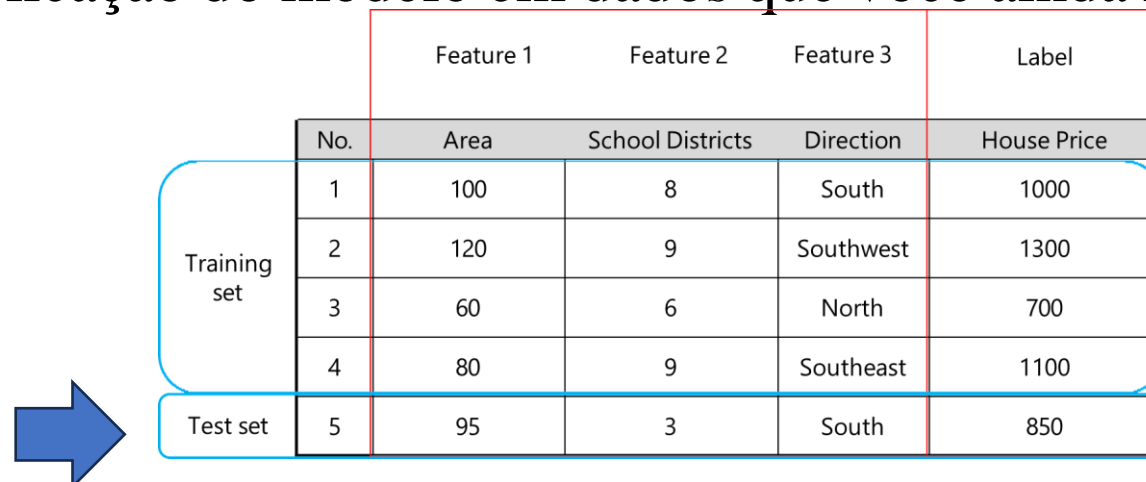
Ou tomar decisões sobre ajustes de parâmetros

# Machine Learning

## Divisão de dados – hold-out

### ■ Conjunto de teste (Test set)

- ✓ O teste refere-se ao processo de usar o modelo obtido após o treinamento para fazer previsões.
- ✓ O conjunto de dados usado para esse propósito é chamado de conjunto de teste, e cada amostra é chamada de amostra de teste.
- ✓ O teste nunca é utilizado para ajuste de modelos ou parâmetros. É usado para simular a aplicação do modelo em dados que você ainda não tem.



		Feature 1	Feature 2	Feature 3	Label
	No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000
	2	120	9	Southwest	1300
	3	60	6	North	700
	4	80	9	Southeast	1100
Test set	5	95	3	South	850

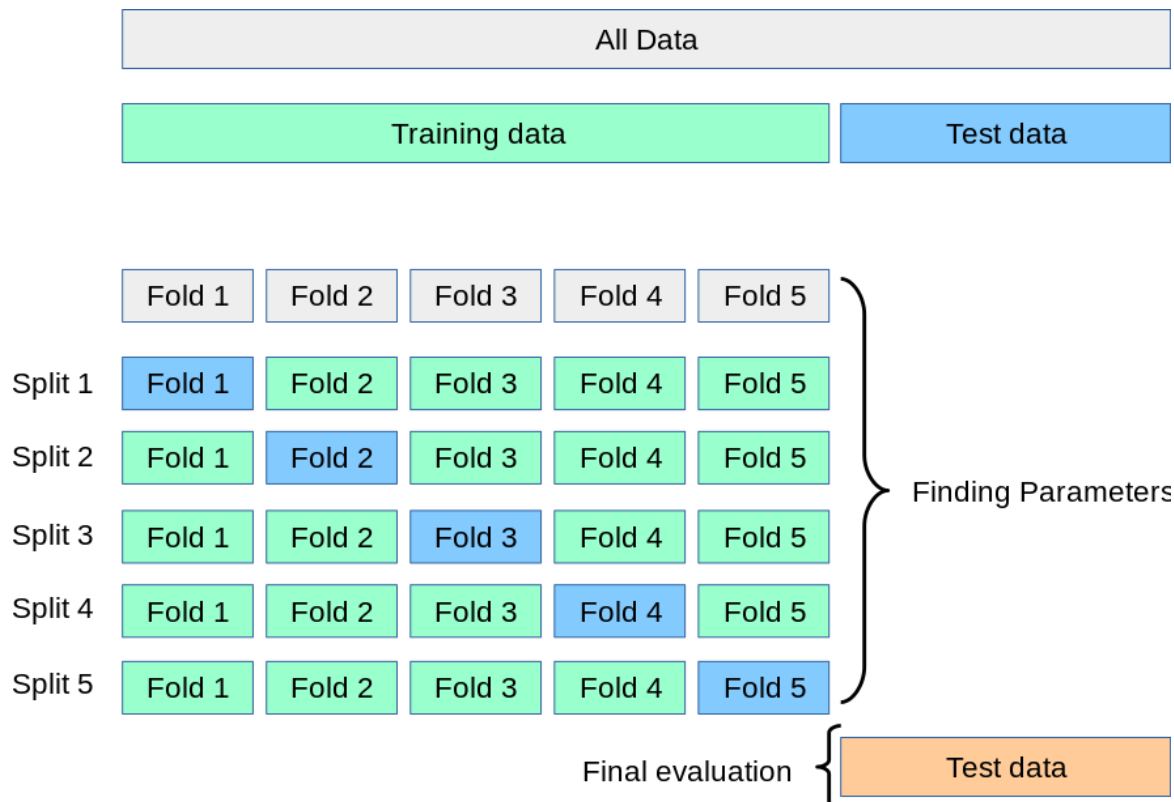


# Machine Learning

## Divisão de dados – Cross-Validation

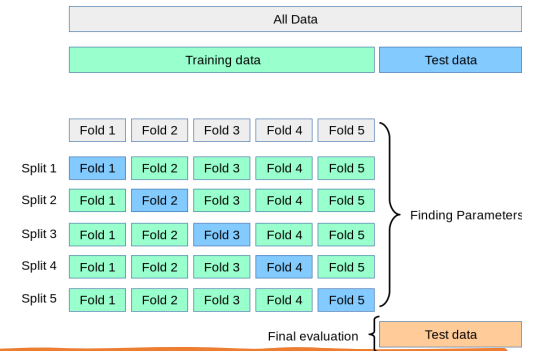
### ■ Conceitos

- ✓ Faz várias partições e garantindo que, em alguma iteração, cada dado seja usado tanto para treino quanto para teste.



# Machine Learning

## Divisão de dados – Cross-Validation



### ■ Conceitos

#### ✓ Vantagens da Cross-Validation

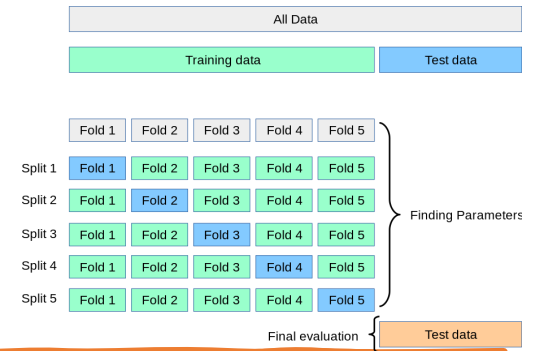
- ✓ Melhor uso dos dados: cada observação figura no conjunto de teste exatamente uma vez e no conjunto de treino  $k-1$  vezes.
- ✓ Estimativa mais estável do desempenho: reduz a dependência de uma única divisão train/test.
- ✓ Robustez estatística: ao relatar a média e o desvio padrão do desempenho, temos uma ideia mais confiável da variância do estimador.

#### ✓ Desvantagens da Cross-Validation

- ✓ Maior custo computacional: é necessário treinar o modelo  $k$  vezes, o que pode ser pesado se o modelo for complexo ou se o dataset for muito grande.
- ✓ Complexidade de implementação: um pouco mais difícil do que um simples hold-out.

# Machine Learning

## Divisão de dados – Cross-Validation



### ■ Como funciona (K-Fold Cross-Validation)

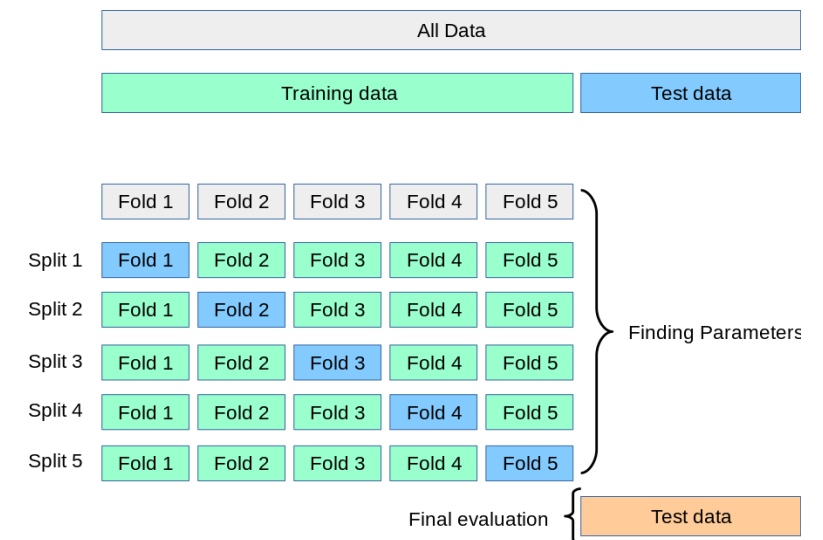
- ✓ Defina um valor  $k$  (por exemplo,  $k=5$  ou  $k=10$ ).
- ✓ Divida o dataset em  $k$  partes (folds) de tamanhos aproximadamente iguais.
- ✓ Para cada uma das  $k$  iterações:
  - ✓ Reserve 1 fold como conjunto de teste. Use as  $k-1$  partes restantes como conjunto de treinamento.
  - ✓ Treine e avalie o modelo.
  - ✓ Calcule uma medida de desempenho (por exemplo, acurácia ou MSE) para cada iteração.
- ✓ A métrica final será a média (e desvio padrão, opcionalmente) dos desempenhos obtidos nas  $k$  iterações.

# Machine Learning

## Divisão de dados – Cross-Validation

### ■ Exemplo

- ✓ Dividimos o dataset em 5 pastas (folds): F1, F2, F3, F4, F5.
- ✓ Iteração 1: Treino = (F2, F3, F4, F5) | Teste = (F1)
- ✓ Iteração 2: Treino = (F1, F3, F4, F5) | Teste = (F2)
- ✓ Iteração 3: Treino = (F1, F2, F4, F5) | Teste = (F3)
- ✓ Iteração 4: Treino = (F1, F2, F3, F5) | Teste = (F4)
- ✓ Iteração 5: Treino = (F1, F2, F3, F4) | Teste = (F5)
- ✓ Métrica final: média dos valores de cada iteração.



# Machine Learning

Conceitos básicos – O que é um bom modelo?

---

- **Capacidade de Generalização**

- ✓ Pode prever com precisão os dados reais do serviço?

- **Interpretabilidade**

- ✓ O resultado da previsão é fácil de interpretar?

- **Velocidade de Previsão**

- ✓ Quanto tempo leva para prever cada dado?

- **Praticidade**

- ✓ A taxa de previsão ainda é aceitável quando o volume de serviço aumenta significativamente?



# Machine Learning


## Conceitos básicos – Validade do Modelo

- **Erro: Diferença entre o resultado previsto pelo modelo após o aprendizado e o resultado real da amostra**
  - ✓ Erro de treinamento: erro obtido ao executar o modelo nos dados de treinamento.
  - ✓ Erro de generalização: erro obtido ao executar o modelo em novas amostras. Obviamente, preferimos um modelo com um erro de generalização menor.
- **Underfitting (Subajuste)**
  - ✓ Ocorre quando o modelo não se ajusta bem o suficiente aos dados de treinamento.
- **Overfitting (Sobreajuste)**
  - ✓ Ocorre quando o erro de treinamento do modelo, após o aprendizado, é pequeno, mas o erro de generalização é grande (indicando baixa capacidade de generalização)

# Machine Learning

## Conceitos básicos – Validade do Modelo

- **Capacidade do modelo: capacidade do modelo de ajustar funções, também chamada de complexidade do modelo.**
  - ✓ Modelos com capacidade insuficiente não conseguem resolver tarefas complexas, podendo ocorrer subajuste (underfitting).
  - ✓ Um modelo de alta capacidade pode resolver tarefas complexas, mas o sobreajuste (overfitting) pode ocorrer se a capacidade for maior do que a necessária para a tarefa.



Underfitting  
Not all features are learned.

Good fitting


Overfitting  
Noises are learned.

# Machine Learning

## Conceitos básicos – Validade do Modelo

### ■ Geralmente, o erro de previsão pode ser dividido em dois tipos: **Erro de Variância** e **Erro de Viés**

- ✓ Baixo viés & baixa variância → Bom modelo
- ✓ Baixo viés & alta variância
- ✓ Alto viés & baixa variância
- ✓ Alto viés & alta variância → Modelo ruim
- ✓ Idealmente, queremos um modelo que possa capturar com precisão as regras nos dados de treinamento e resumir os dados invisíveis (novos dados). No entanto, geralmente é impossível para o modelo realizar ambas as tarefas ao mesmo tempo






# Machine Learning

## Conceitos básicos – Validade do Modelo

### ■ Complexidade do Modelo e Erro

- ✓ À medida que a complexidade do modelo aumenta, o erro de treinamento diminui.
- ✓ À medida que a complexidade do modelo aumenta, o erro de teste diminui até certo ponto e depois começa a aumentar novamente, formando uma curva convexa.



# Machine Learning

## Avaliação do modelo – Regressão

### ■ **MAE (Mean Absolute Percentage Error)**

- ✓ É a média dos valores absolutos das diferenças entre o valor real e o valor predito.
- ✓ Quanto mais próximo de 0, melhor o modelo se ajusta aos dados de treinamento.
- ✓ Indica, em média, o tamanho do erro (sem sinal) entre predição e valor real.
  - ✓ É fácil de interpretar, pois está na mesma escala da variável-alvo (por exemplo, se você estiver prevendo preços em Reais, a MAE estará em Reais).
  - ✓ **Exemplo:** Se você tem um modelo que prediz o preço de imóveis em uma cidade e descobre que o MAE é de R\$ 5.000, isso significa que, em média, o modelo erra cerca de R\$ 5.000 em cada previsão de preço.
  - ✓ Mais robusto a outliers em comparação ao MSE, pois não eleva ao quadrado as diferenças.

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

# Machine Learning

## Avaliação do modelo - Classificação

### ■ Erro Médio Quadrático (MSE)

- ✓ É a média dos quadrados das diferenças entre o valor real e o valor predito.
- ✓ O MSE penaliza mais fortemente erros grandes (outliers) em comparação ao MAE.
  - ✓ Muito utilizado como função de custo em regressão linear e outros modelos de Machine Learning (por exemplo, Redes Neurais)
  - ✓ Se existirem valores atípicos extremamente altos ou baixos, o MSE aumentará consideravelmente, chamando atenção para esses grandes erros
- ✓ Se o MSE é de  $2,5 \times 10^8$ , significa que em média (ao quadrado) o erro é de 15.811 (raiz de  $2,5 \times 10^8$ ). Essa interpretação não está diretamente na escala do preço (por isso muitas vezes preferimos também analisar o RMSE, como veremos adiante).

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

# Machine Learning

## Avaliação do modelo - Classificação

### ■ **RMSE (Root Mean Squared Error)**

- ✓ É simplesmente a raiz quadrada do MSE
- ✓ Interpretação na mesma unidade dos valores de saída, porém preservando a ideia de penalizar mais erros grandes.
  - ✓ É frequentemente utilizado para ter uma noção de erro na mesma escala do problema.
  - ✓ Útil em tarefas onde erros maiores devam pesar mais, mas ainda se deseje uma métrica “na unidade” do que se está prevendo.
- ✓ Exemplo: Na previsão de temperatura (em graus Celsius), o RMSE de 2°C indica, aproximadamente, que no “quadrado médio” das previsões, o desvio gira em torno de 2 graus em relação ao valor real.

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2}$$

# Machine Learning

## Avaliação do modelo - Classificação

### ■ **MAPE (Mean Absolute Percentage Error)**

- ✓ Calcula a média dos erros em termos percentuais, ou seja, leva em conta o quão grande é o erro em relação ao valor real.
  - ✓ Indica, em média, qual a porcentagem de desvio em relação ao valor real
  - ✓ Cuidado: se  $y_i$  for muito próximo de zero, o MAPE pode explodir ou ficar impreciso.
- ✓ **Quando usar:** cenários em que o tamanho relativo do erro interessa mais do que o erro absoluto (em vendas é importante saber se erramos 10% ou 50% das vendas)
  - ✓ Na previsão de vendas de uma loja, podemos dizer que o modelo erra em média 8% das vendas diárias. Independentemente de a loja vender 100 ou 1000 itens por dia, essa taxa de erro percentual mantém a comparação coerente.

$$MAPE = \frac{1}{m} \sum_{i=1}^m \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

# Machine Learning

## Avaliação do modelo - Classificação

---

### ■ **Conclusão e Escolha da Métrica**

- ✓ Não existe “melhor” métrica absoluta: a escolha depende do contexto.
- ✓ Se você quer simplicidade e não deseja penalizar erros grandes excessivamente, MAE ou MAPE (se preferir porcentagens) podem ser mais apropriados.
- ✓ Se você quer focar na minimização de grandes erros ou usar métodos tradicionais de otimização de regressão, opte por MSE ou RMSE.
- ✓ Se comparações relativas são importantes (por exemplo, comparar erros em diferentes escalas ou em diferentes produtos/projetos), MAPE pode ser o mais intuitivo.

# Machine Learning

## Avaliação do modelo - Classificação

Real \ Predito	Predito		Total
	SIM	NAO	
SIM	TP	FN	
NAO	FP	TN	
Total	P	N	P+N

### ■ Termos e definições

- ✓ P: Positivo, indicando o número de casos realmente positivos nos dados.
- ✓ N: Negativo, indicando o número de casos realmente negativos nos dados.
- ✓ TP (True Positive ou Verdadeiro Positivo): número de casos positivos que são classificados corretamente pelo classificador.
- ✓ TN (True Negative ou Verdadeiro Negativo): número de casos negativos que são classificados corretamente pelo classificador.
- ✓ FP (False Positive ou Falso Positivo): número de casos positivos classificados incorretamente (ou seja, deveriam ser “não”, mas classificou-se como “sim”).
- ✓ FN (False Negative ou Falso Negativo): número de casos negativos que são classificados incorretamente (ou seja, deveriam ser “sim”, mas classificou-se como “não”).

# Machine Learning

## Avaliação do modelo - Classificação

### ■ Matriz de confusão

- ✓ Uma tabela de dimensão  $2 \times 2$ . O valor  $c_{ij}$  das primeiras 2 linhas e 2 colunas indica quantos casos que de fato pertencem à classe  $i$  foram classificados como classe  $j$  pelo classificador.
- ✓ Idealmente, para um classificador com alta exatidão, a maior parte das predições deve estar concentrada na diagonal que vai de  $c_{1,1}$  a  $c_{2,2}$ . Ou seja, desejamos que  $FP$  e  $FN$  sejam próximos de 0.

Real \ Predito			
	SIM	NAO	Total
SIM	TP	FN	
NAO	FP	TN	
Total	P	N	P+N



# Machine Learning

## Avaliação do modelo - Classificação

Real \ Predito	Predito		Total
	SIM	NAO	
SIM	TP	FN	
NAO	FP	TN	
Total	P	N	P+N

Medida	Fórmula
<b>Acurácia</b> ou <b>Taxa de Reconhecimento</b>	$\frac{TP+TN}{P+N}$
<b>Taxa de Erro</b> ou <b>Taxa de Misclassificação</b>	$\frac{FP + FN}{P + N}$
<b>Sensibilidade, Taxa de Verdadeiros Positivos</b> ou <b>Recall</b>	$\frac{TP}{P}$
<b>Especificidade</b> ou <b>Taxa de Verdadeiros Negativos</b>	$\frac{TN}{N}$
<b>Precisão</b>	$\frac{TP}{TP+FP}$
<b>F1</b> , média harmônica de <b>Recall</b> e <b>Precisão</b>	$2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$
<b>F<math>\beta</math></b> , onde $\beta$ é um número real não negativo	$(1 + \beta^2) \times \frac{\text{Precisão} \times \text{Recall}}{\beta^2 \times \text{Precisão} + \text{Recall}}$

# Machine Learning

## Avaliação do modelo - Classificação

### ■ Exemplo

- ✓ Treinamos um modelo de machine learning para identificar se o objeto em uma imagem é um gato. Utilizamos 200 imagens para verificar o desempenho do modelo. Das 200 imagens, em 170 há gatos (positivo real) e em 30 não há gatos (negativo real). O modelo classificou 160 imagens como contendo gatos (classe “sim”), errando em 20 delas e 40 como não contendo gatos (classe “não”), mas somente 10 não continham gatos.
- ✓ A matriz de confusão resultante (linhas = classe real; colunas = classe prevista) ficou.

	Predito: Gato	Predito: Não Gato	Total
Real: Gato	TP = 140	FN = 30	170
Real: Não Gato	FP = 20	TN = 10	30
Total	160	40	200

# Machine Learning

## Avaliação do modelo - Classificação

### ■ Exemplo

✓ A matriz de confusão resultante (linhas = classe real; colunas = classe prevista) ficou.

✓ A partir disso, temos:

✓ Precisão:  $\frac{TP}{TP+FP} = \frac{140}{140+20} = 87,5\%$

✓ Recall:  $\frac{TP}{P} = \frac{140}{170} = 82,4\%$

✓ F1-Score:  $2 \times \frac{0.875 \times 0.824}{0.875+0.824} = 84,9\%$

✓ Acurácia:  $\frac{TP+TN}{P+N} = \frac{140+10}{170+30} = 75\%$


✓ Taxa de Erro:  $\frac{FP+FN}{P+N} = \frac{20+30}{200} = 25\%$

	Predito: Gato	Predito: Não Gato	Total
Real: Gato	TP = 140	FN = 30	170
Real: Não Gato	FP = 20	TN = 10	30
Total	160	40	200



Dúvidas?

---



Até a próxima...



Apresentador

**Thales Levi Azevedo Valente**

E-mail:

[thales.l.a.valente@gmail.com](mailto:thales.l.a.valente@gmail.com)